

尚硅谷大数据技术之 DataX

(作者: 尚硅谷大数据研究院)

版本: V1.0

第1章 概述

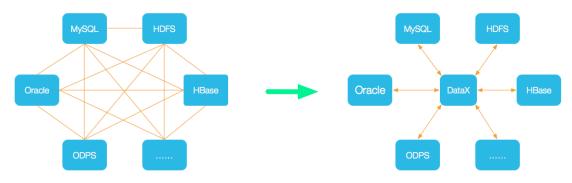
1.1 什么是 DataX

DataX 是阿里巴巴开源的一个异构数据源离线同步工具,致力于实现包括关系型数据库(MySQL、Oracle等)、HDFS、Hive、ODPS、HBase、FTP等各种异构数据源之间稳定高效的数据同步功能。



1.2 DataX 的设计

为了解决异构数据源同步问题,DataX 将复杂的网状的同步链路变成了星型数据链路,DataX 作为中间传输载体负责连接各种数据源。当需要接入一个新的数据源的时候,只需要将此数据源对接到 DataX,便能跟己有的数据源做到无缝数据同步。



1.3 支持的数据源

DataX 目前已经有了比较全面的插件体系,主流的 RDBMS 数据库、NOSQL、大数据 更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



计算系统都已经接入。

| 类型 | 数据源 | Reader(读) | Writer(写) | 文档 |
|--------------|---------------------|-----------|-----------|-----|
| RDBMS 关系型数据库 | MySQL | √ | √ | 读、写 |
| | Oracle | √ | √ | 读、写 |
| | SQLServer | √ | √ | 读、写 |
| | PostgreSQL | √ | √ | 读、写 |
| | DRDS | √ | √ | 读、写 |
| | 通用RDBMS(支持所有关系型数据库) | √ | √ | 读、写 |
| 阿里云数仓数据存储 | ODPS | √ | √ | 读、写 |
| | ADS | | √ | 写 |
| | OSS | √ | √ | 读、写 |
| | OCS | √ | √ | 读、写 |
| NoSQL数据存储 | OTS | √ | √ | 读、写 |
| | Hbase0.94 | √ | √ | 读、写 |
| | Hbase1.1 | √ | √ | 读、写 |
| | Phoenix4.x | √ | √ | 读、写 |
| | Phoenix5.x | √ | √ | 读、写 |
| | MongoDB | √ | √ | 读、写 |
| | Hive | √ | √ | 读、写 |
| | Cassandra | √ | √ | 读、写 |
| 无结构化数据存储 | TxtFile | v | √ | 读、写 |
| | FTP | √ | √ | 读、写 |
| | HDFS | √ | √ | 读、写 |
| | Elasticsearch | | √ | 写 |
| 时间序列数据库 | OpenTSDB | √ | | 读 |
| | TSDB | √ | √ | 读、写 |

1.4 框架设计







Reader: 数据采集模块,负责采集数据源的数据,将数据发送给Framework。

Writer: 数据写入模块,负责不断向Framework取数据,并将数据写入到目的端。

Framework: 用于连接reader和writer,作为两者的数据传输通道,并处理缓冲,流控,并发,数据转换等核心技术问题。

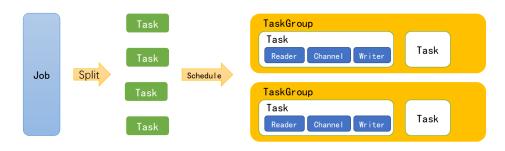
让天下没有难学的技术



1.5 运行原理







Job: 单个作业的管理节点,负责数据清理、子任务划分、TaskGroup监控管理。

Task: 由Job切分而来,是DataX作业的最小单元,每个Task负责一部分数据的同步工作。

Schedule:将Task组成TaskGroup,单个TaskGroup的并发数量为5。

TaskGroup: 负责启动Task。

让天下没有难学的技术

举例来说,用户提交了一个 DataX 作业,并且配置了 20 个并发,目的是将一个 100 张 分表的 mysgl 数据同步到 odps 里面。 DataX 的调度决策思路是:

- 1) DataXJob 根据分库分表切分成了 100 个 Task。
- 2)根据 20 个并发,DataX 计算共需要分配 4 个 TaskGroup。
- 3)4个 TaskGroup 平分切分好的 100 个 Task,每一个 TaskGroup 负责以 5 个并发共计运行 25 个 Task。

1.6 与 Sqoop 的对比

| 功能 | DataX | Sqoop | |
|----------|----------------|----------------|--|
| 运行模式 | 单进程多线程 | MR | |
| MySQL 读写 | 单机压力大; | MR 模式重,写出错处理麻烦 | |
| | 读写粒度容易控制 | | |
| Hive 读写 | 单机压力大 | 很好 | |
| 文件格式 | orc 支持 | orc 不支持,可添加 | |
| 分布式 | 不支持,可以通过调度系统规避 | 支持 | |
| 流控 | 有流控功能 | 需要定制 | |
| 统计信息 | 已有一些统计,上报需定制 | 没有,分布式的数据收集不方便 | |
| 数据校验 | 在 core 部分有校验功能 | 没有,分布式的数据收集不方便 | |
| 监控 | 需要定制 | 需要定制 | |
| 社区 | 开源不久, 社区不活跃 | 一直活跃,核心部分变动很少 | |

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



第2章 快速入门

2.1 官方地址

下载地址: http://datax-opensource.oss-cn-hangzhou.aliyuncs.com/datax.tar.gz

源码地址: https://github.com/alibaba/DataX

2.2 前置要求

- Linux
- JDK(1.8 以上,推荐 1.8)
- Python(推荐 Python2.6.X)

2.3 安装

- 1) 将下载好的 datax.tar.gz 上传到 hadoop102 的/opt/software
- 2)解压 datax.tar.gz 到/opt/module

[atguigu@hadoop102 software]\$ tar -zxvf datax.tar.gz -C /opt/module/

3)运行自检脚本

[atguigu@hadoop102 bin]\$ cd /opt/module/datax/bin/ [atguigu@hadoop102 bin]\$ python datax.py /opt/module/datax/job/job.json

```
| 2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - Set JobContainer starts to do prepare ... |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Estemantical | do prepare work |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Estemantical | do prepare work |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Estemantical | do prepare work |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Estemantical | splits to [1] tasks. |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Estemantical | splits to [1] tasks. |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Estemantical | splits to [1] tasks. |
2019-05-08 | 22:001:18.19 | 15:00-01 | NRO | JobContainer - DataX | Reader., Job | Start | National | Start | Start
```



第3章 使用案例

3.1 从 stream 流读取数据并打印到控制台

1) 查看配置模板

```
[atguigu@hadoop102 bin]$ python datax.py -r streamreader -w streamwriter
DataX (DATAX-OPENSOURCE-3.0), From Alibaba!
Copyright (C) 2010-2017, Alibaba Group. All Rights Reserved.
Please refer to the streamreader document:
      https://github.com/alibaba/DataX/blob/master/streamreader/doc/streamreader.md
Please refer to the streamwriter document:
      https://github.com/alibaba/DataX/blob/master/streamwriter/doc/streamwriter.md
Please save the following configuration as a json file and use
      python {DATAX HOME}/bin/datax.py {JSON FILE NAME}.json
to run the job.
    "job": {
         "content": [
                   "reader": {
                        "name": "streamreader",
                        "parameter": {
                            "column": [],
                            "sliceRecordCount": ""
                        }
                   },
                   "writer": {
                        "name": "streamwriter",
                        "parameter": {
                            "encoding": "",
                            "print": true
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
}
}

],

"setting": {
    "speed": {
        "channel": ""
     }
}
```

2) 根据模板编写配置文件

[atguigu@hadoop102 job]\$ vim stream2stream.json

填写以下内容:

```
"job": {
  "content": [
       "reader": {
          "name": "streamreader",
          "parameter": {
            "sliceRecordCount": 10,
            "column": [
                 "type": "long",
                 "value": "10"
               },
                 "type": "string",
                 "value": "hello, DataX"
       },
       "writer": {
          "name": "streamwriter",
          "parameter": {
            "encoding": "UTF-8",
            "print": true
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
}
}

}

],

"setting": {
    "speed": {
        "channel": 1
      }
}
```

3)运行

```
[atguigu@hadoop102 job]$
/opt/module/datax/bin/datax.py /opt/module/datax/job/stream2stream.json
```

3.2 读取 MySQL 中的数据存放到 HDFS

3.2.1 查看官方模板

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
},
          "writer": {
                "name": "hdfswriter",
                "parameter": {
                     "column": [],
                     "compress": "",
                     "defaultFS": "",
                     "fieldDelimiter": "",
                     "fileName": "",
                     "fileType": "",
                     "path": "",
                     "writeMode": ""
],
"setting": {
     "speed": {
          "channel": ""
```

mysqlreader 参数解析:



mysqlreader参数解析



```
"reader": {
                                         name: reader名
          "name": "mysqlreader",
                                         column: 需要同步的列名集合,使用JSON数组描述自带信息,
          "parameter": {
    "column": [],
                                                 *代表所有列
                                         jdbcUrl: 对数据库的JDBC连接信息,使用JSON数组描述,
支持多个连接地址
             "connection": [
                 "jdbcUrl": [],
                                         table: 需要同步的表,支持多个
                "table": [ ]
["querySql:[]]
                                         querySql: 自定义SQL,配置它后,mysqlreader直接忽略table、
                                                 column, where
                                         password: 数据库用户名对应的密码
             "password": "",
            "username": "",
["where": ""]
                                         username: 数据库用户名
            ["splitPk": ""]
                                         where: 筛选条件
                                         splitPK: 数据分片字段,一般是主键,仅支持整型
注意:【】中的参数为可选参数
```

上天下没有难停的技术



hdfswriter 参数解析:





```
name: writer名
"writer": {
                                     column: 写入数据的字段, 其中name指定字段名, type指定类型
           "name": "hdfswriter",
                                     compress: hdfs文件压缩类型, 默认不填写意味着没有压缩。
           "parameter": {
             "column": [],
                                     defaultFS: hdfs文件系统namenode节点地址,格式: hdfs://ip:端口
             "compress": ""
             "defaultFS": "",
                                     fieldDelimiter: 字段分隔符
             "fieldDelimiter": "",
             "fileName": "",
"fileType": "",
                                     fileName: 写入文件名
                                     fileType: 文件的类型,目前只支持用户配置为"text"或"orc"
             "path": ""
             "writeMode": ""
                                     path: 存储到Hadoop hdfs文件系统的路径信息
                                     writeMode: hdfswriter写入前数据清理处理模式:
(1)append: 写入前不做任何处理,DataX hdfswriter直接使用filename写入,
        }
                                                        并保证文件名不冲突。
                                               (2)nonConflict: 如果目录下有fileName前缀的文件,直接报错。
```

让天下没有难学的技术

3.2.2 准备数据

1) 创建 student 表

```
mysql> create database datax;
mysql> use datax;
mysql> create table student(id int,name varchar(20));
```

2) 插入数据

mysql> insert into student values(1001, 'zhangsan'),(1002, 'lisi'),(1003, 'wangwu');

3.2.3 编写配置文件

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



```
"jdbcUrl": [
                                   "jdbc:mysql://hadoop102:3306/datax"
                              ],
                              "table": [
                                   "student"
                              ]
                         }
                    ],
                    "username": "root",
                    "password": "000000"
               }
          },
          "writer": {
               "name": "hdfswriter",
               "parameter": {
                    "column": [
                              "name": "id",
                              "type": "int"
                         },
                              "name": "name",
                              "type": "string"
                         }
                    ],
                    "defaultFS": "hdfs://hadoop102:9000",
                    "fieldDelimiter": "\t",
                    "fileName": "student.txt",
                    "fileType": "text",
                    "path": "/",
                    "writeMode": "append"
          }
],
"setting": {
     "speed": {
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
"channel": "1"
}
}
}
```

3.2.4 执行任务

[atguigu@hadoop102 datax]\$ bin/datax.py job/mysql2hdfs.json 2019-05-17 16:02:16.581 [job-0] INFO JobContainer -任务启动时刻 : 2019-05-17 16:02:04 任务结束时刻 : 2019-05-17 16:02:16 任务总计耗时 12s 任务平均流量 3B/s记录写入速度 0rec/s 读出记录总数 3 读写失败总数 0

3.2.5 查看 hdfs

Browse Directory



注意: HdfsWriter 实际执行时会在该文件名后添加随机的后缀作为每个线程写入实际文件名。

3.2.6 关于 HA 的支持

```
"hadoopConfig":{

"dfs.nameservices": "ns",

"dfs.ha.namenodes.ns": "nn1,nn2",

"dfs.namenode.rpc-address.ns.nn1": "主机名:端口",

"dfs.namenode.rpc-address.ns.nn2": "主机名:端口",
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



```
"dfs.client.failover.proxy.provider.ns":

"org.apache.hadoop.hdfs.server.namenode.ha.ConfiguredFailoverProxyProvider"
}
```

3.3 读取 HDFS 数据写入 MySQL

1) 将上个案例上传的文件改名

[atguigu@hadoop102 datax]\$ hadoop fs -mv /student.txt* /student.txt

2) 查看官方模板

```
[atguigu@hadoop102 datax]$ python bin/datax.py -r hdfsreader -w mysqlwriter
     "job": {
          "content": [
                    "reader": {
                         "name": "hdfsreader",
                         "parameter": {
                              "column": [],
                              "defaultFS": "",
                              "encoding": "UTF-8",
                              "fieldDelimiter": ",",
                              "fileType": "orc",
                              "path": ""
                    },
                    "writer": {
                         "name": "mysqlwriter",
                         "parameter": {
                              "column": [],
                              "connection": [
                                        "jdbcUrl": "",
                                        "table": []
                              ],
                              "password": "",
```



3) 创建配置文件

```
[atguigu@hadoop102 datax]$ vim job/hdfs2mysql.json
    "job": {
          "content": [
                   "reader": {
                         "name": "hdfsreader",
                         "parameter": {
                             "column": ["*"],
                             "defaultFS": "hdfs://hadoop102:9000",
                             "encoding": "UTF-8",
                             "fieldDelimiter": "\t",
                             "fileType": "text",
                             "path": "/student.txt"
                         }
                   },
                   "writer": {
                         "name": "mysqlwriter",
                         "parameter": {
                             "column": [
                                   "id",
                                  "name"
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
],
                         "connection": [
                              {
                                   "jdbcUrl": "jdbc:mysql://hadoop102:3306/datax",
                                   "table": ["student2"]
                              }
                         ],
                         "password": "000000",
                         "username": "root",
                         "writeMode": "insert"
               }
          }
     ],
     "setting": {
          "speed": {
               "channel": "1"
     }
}
```

4) 在 MySQL 的 datax 数据库中创建 student2

mysql> use datax;

mysql> create table student2(id int,name varchar(20));

5) 执行任务

[atguigu@hadoop102 datax]\$ bin/datax.py job/hdfs2mysql.json

```
      2019-05-17 16:21:53.616 [job-0] INFO
      JobContainer -

      任务启动时刻
      : 2019-05-17 16:21:41

      任务结束时刻
      : 2019-05-17 16:21:53

      任务总计耗时
      : 11s

      任务平均流量
      : 3B/s

      记录写入速度
      : 0rec/s

      读出记录总数
      : 3

      读写失败总数
      : 0
```

6) 查看 student2 表



```
mysql> select * from student2;
+-----+
| id | name |
+-----+
| 1001 | zhangsan |
| 1002 | lisi |
| 1003 | wangwu |
+-----+
3 rows in set (0.00 sec)
```

第4章 Oracle 数据库

以下操作使用 root 账号。

4.1 oracle 数据库简介

Oracle Database,又名 Oracle RDBMS,或简称 Oracle。是甲骨文公司的一款关系数据库管理系统。它是在数据库领域一直处于领先地位的产品。可以说 Oracle 数据库系统是目前世界上流行的关系数据库管理系统,系统可移植性好、使用方便、功能强,适用于各类大、中、小、微机环境。它是一种高效率、可靠性好的、适应高吞吐量的数据库解决方案。

4.2 安装前的准备

4.2.1 安装依赖

yum install -y bc binutils compat-libcap1 compat-libstdc++33 elfutils-libelf elfutils-libelf-devel fontconfig-devel glibc glibc-devel ksh libaio libaio-devel libX11 libXau libXi libXtst libXrender libXrender-devel libgcc libstdc++ libstdc++-devel libxcb make smartmontools sysstat kmod* gcc-c++ compat-libstdc++-33

4.2.2 配置用户组

Oracle 安装文件不允许通过 root 用户启动,需要为 oracle 配置一个专门的用户。

1) 创建 sql 用户组

[root@hadoop102 software]#groupadd sql



2) 创建 oracle 用户并放入 sql 组中

[root@hadoop102 software]#useradd oracle -g sql

3) 修改 oracle 用户登录密码,输入密码后即可使用 oracle 用户登录系统

[root@hadoop102 software]#passwd oracle

4.2.3 上传安装包并解压

注意:19c 需要把软件包直接解压到 ORACLE_HOME 的目录下

[root@hadoop102 software]# mkdir -p /home/oracle/app/oracle/product/19.3.0/dbhome_1 [root@hadoop102 software]# unzip LINUX.X64_193000_db_home.zip -d /home/oracle/app/oracle/product/19.3.0/dbhome_1

修改所属用户和组

[root@hadoop102 dbhome 1]# chown -R oracle:sql/home/oracle/app/

4.2.4 修改配置文件 sysctl.conf

[root@hadoop102 module]# vim /etc/sysctl.conf

删除里面的内容,添加如下内容:

net.ipv4.ip local port range = 9000 65500

fs.file-max = 6815744

kernel.shmall = 10523004

kernel.shmmax = 6465333657

kernel.shmmni = 4096

kernel.sem = 250 32000 100 128

net.core.rmem default=262144

net.core.wmem default=262144

net.core.rmem max=4194304

net.core.wmem max=1048576

fs.aio-max-nr = 1048576

参数解析:

net.ipv4.ip_local_port_range : 可使用的 IPv4 端口范围

fs.file-max: 该参数表示文件句柄的最大数量。文件句柄设置表示在 linux 系统中可以 打开的文件数量。

kernel.shmall: 该参数表示系统一次可以使用的共享内存总量(以页为单位)

kernel.shmmax: 该参数定义了共享内存段的最大尺寸(以字节为单位)

kernel.shmmni: 这个内核参数用于设置系统范围内共享内存段的最大数量

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



kernel.sem: 该参数表示设置的信号量。

net.core.rmem default: 默认的 TCP 数据接收窗口大小 (字节)。

net.core.wmem default: 默认的 TCP 数据发送窗口大小 (字节)。

net.core.rmem max: 最大的 TCP 数据接收窗口 (字节)。

net.core.wmem max: 最大的 TCP 数据发送窗口 (字节)。

fs.aio-max-nr: 同时可以拥有的的异步 IO 请求数目。

4.2.5 修改配置文件 limits.conf

[root@hadoop102 module]# vim /etc/security/limits.conf

在文件末尾添加:

oracle soft nproc 2047

oracle hard nproc 16384

oracle soft nofile 1024

oracle hard nofile 65536

重启机器生效。

4.3 安装 Oracle 数据库

4.3.1 设置环境变量

[oracle@hadoop102 dbhome_1]# vim /home/oracle/.bash_profile

添加:

#ORACLE HOME

export ORACLE_BASE=/home/oracle/app/oracle

export ORACLE HOME=/home/oracle/app/oracle/product/19.3.0/dbhome 1

export PATH=\$PATH:\$ORACLE HOME/bin

export ORACLE SID=orcl

export NLS LANG=AMERICAN AMERICA.ZHS16GBK

[oracle@hadoop102 ~]\$ source /home/oracle/.bash_profile

4.3.2 进入虚拟机图像化页面操作

[oracle@hadoop102 ~]# cd /opt/module/oracle

[oracle@hadoop102 database]# ./runInstaller



4.3.3 安装数据库

1) 选择仅安装数据库软件



2) 选择单实例数据库安装





3) 选择企业版, 默认



4)设置安装位置

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网





5) 操作系统组设置

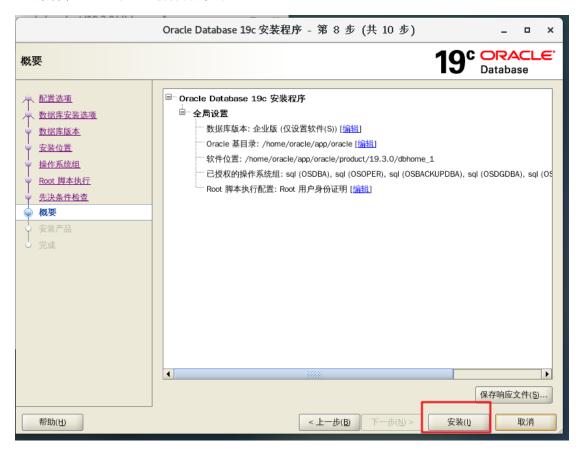


6) 配置 root 脚本自动执行 更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网





7) 条件检查通过后,选择开始安装



8)运行 root 脚本 更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网





9) 安装完成



更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



4.4 设置 Oracle 监听

4.4.1 命令行输入以下命令



4.4.2 选择添加





4.4.3 设置监听名,默认即可



4.4.4 选择协议, 默认即可



更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



4.4.5 设置端口号, 默认即可



4.4.6 配置更多监听,默认



更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



4.4.7 完成



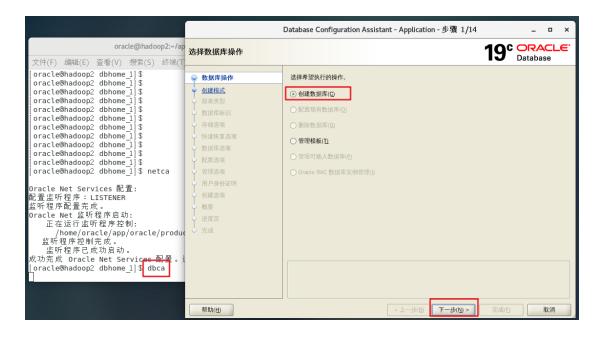


4.5 创建数据库

4.5.1 进入创建页面

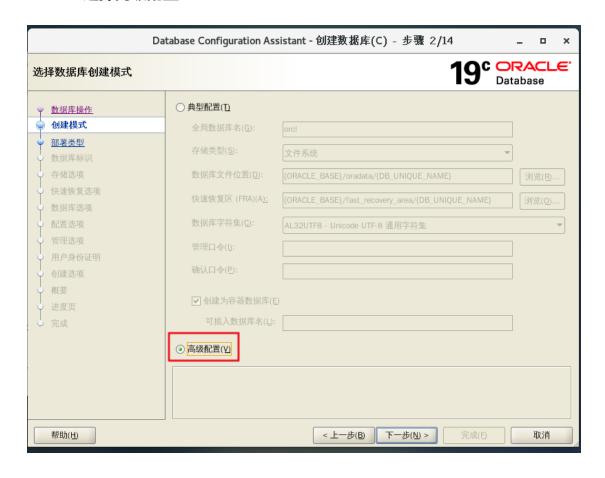
[oracle@hadoop2 ~]\$ dbca

4.5.2 选择创建数据库





4.5.3 选择高级配置





4.5.4 选择数据仓库



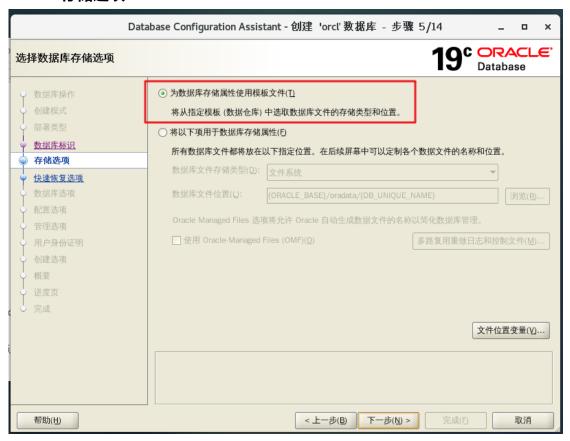


4.5.5 将图中所示对勾去掉





4.5.6 存储选项



4.5.7 快速恢复选项





4.5.8 选择监听程序



更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



4.5.9 如图设置





4.5.10 使用自动内存管理





4.5.11 管理选项, 默认





4.5.12 设置统一密码



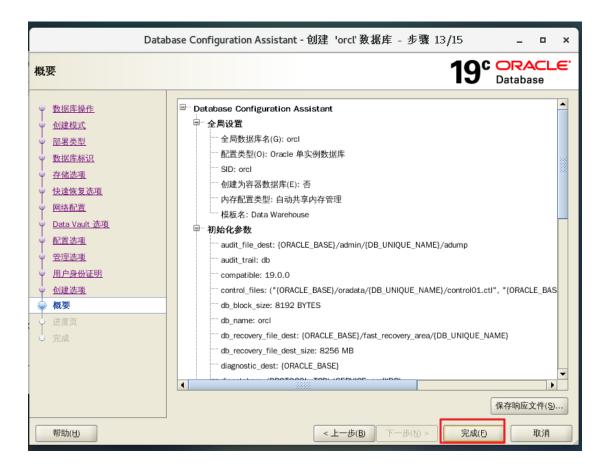


4.5.13 创建选项,选择创建数据库





4.5.14 概要, 点击完成





4.5.15 等待安装





更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



4.6 简单使用

4.6.1 开启,关闭监听服务

开启服务:

[oracle@hadoop102 ~]\$ lsnrctl start

关闭服务:

[oracle@hadoop102 ~]\$ lsnrctl stop

4.6.2 进入命令行

[oracle@hadoop102 ~]\$ sqlplus

SQL*Plus: Release 19.0.0.0.0 - Production on Fri Sep 3 01:44:30 2021

Version 19.3.0.0.0

Copyright (c) 1982, 2019, Oracle. All rights reserved.

Enter user-name: system

Enter password: (这里输入之前配置的统一密码)

Connected to:

Oracle Database 19c Enterprise Edition Release 19.0.0.0.0 - Production

Version 19.3.0.0.0

SQL>

4.6.3 创建用户并授权

SQL> create user atguigu identified by 000000;

User created.

SQL> grant create session, create table, create view, create sequence, unlimited tablespace to atguigu;

Grant succeeded.

4.6.4 进入 atguigu 账号, 创建表

SQL>create TABLE student(id INTEGER,name VARCHAR2(20));

SQL>insert into student values (1,'zhangsan');

SQL> select * from student;

ID NAME

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



1 zhangsan

注意:安装完成后重启机器可能出现 ORACLE not available 错误,解决方法如下:

[oracle@hadoop102 \sim]\$ sqlplus / as sysdba

SQL>startup

SQL>conn atguigu

Enter password:

4.7 Oracle 与 MySQL 的 SQL 区别

| 类型 | Oracle | MySQL | |
|--------------------------|-------------------|--------------|--|
| 整型 | number(N)/integer | int/integer | |
| 浮点型 | float | float/double | |
| 字符串类型 | varchar2(N) | varchar(N) | |
| NULL | " | null 和"不一样 | |
| 分页 | rownum | limit | |
| " " | 限制很多,一般不让用 | 与单引号一样 | |
| 价格 | 闭源,收费 | 开源,免费 | |
| 主键自动增长 | X | √ | |
| if not exists | X | √ | |
| auto_increment | × | √ | |
| create database | X | √ | |
| select * from table as t | × | √ | |

4.8 DataX 案例

4.8.1 从 Oracle 中读取数据存到 MySQL

1) MySQL 中创建表

[oracle@hadoop102 ~]\$ mysql -uroot -p000000

mysql> create database oracle;

mysql> use oracle;

mysql> create table student(id int,name varchar(20));



2) 编写 datax 配置文件

```
[oracle@hadoop102\sim] \$\ vim\ /opt/module/datax/job/oracle2mysql.json
     "job": {
          "content": [
                    "reader": {
                         "name": "oraclereader",
                         "parameter": {
                              "column": ["*"],
                              "connection": [
                                   {
                                        "jdbcUrl":
["jdbc:oracle:thin:@hadoop102:1521:orcl"],
                                        "table": ["student"]
                                   }
                              ],
                              "password": "000000",
                              "username": "atguigu"
                    },
                    "writer": {
                         "name": "mysqlwriter",
                         "parameter": {
                              "column": ["*"],
                              "connection": [
                                        "jdbcUrl": "jdbc:mysql://hadoop102:3306/oracle",
                                        "table": ["student"]
                                   }
                              ],
                              "password": "000000",
                              "username": "root",
                              "writeMode": "insert"
                    }
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
],
    "setting": {
        "speed": {
            "channel": "1"
        }
    }
}
```

3) 执行命令

```
[oracle@hadoop102 ~]$
```

/opt/module/datax/bin/datax.py /opt/module/datax/job/oracle2mysql.json

查看结果:

```
mysql> select * from student;
+-----+
| id | name |
+-----+
| 1 | zhangsan |
+-----+
```

4.8.2 读取 Oracle 的数据存入 HDFS 中

1)编写配置文件

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
"password": "000000",
                         "username": "atguigu"
               },
               "writer": {
                    "name": "hdfswriter",
                    "parameter": {
                         "column": [
                                   "name": "id",
                                   "type": "int"
                              },
                                   "name": "name",
                                   "type": "string"
                         ],
                         "defaultFS": "hdfs://hadoop102:9000",
                         "fieldDelimiter": "\t",
                         "fileName": "oracle.txt",
                         "fileType": "text",
                         "path": "/",
                         "writeMode": "append"
                    }
               }
    ],
     "setting": {
          "speed": {
               "channel": "1"
     }
}
```

2) 执行

[oracle@hadoop102 datax]\$ bin/datax.py job/oracle2hdfs.json

3) 查看 HDFS 结果

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网





第5章 MongoDB

5.1 什么是 MongoDB

MongoDB 是由 C++语言编写的,是一个基于分布式文件存储的开源数据库系统。 MongoDB 旨在为 WEB 应用提供可扩展的高性能数据存储解决方案。MongoDB 将数据存储为一个文档,数据结构由键值(key=>value)对组成。MongoDB 文档类似于 JSON 对象。 字段值可以包含其他文档,数组及文档数组。



5.2 MongoDB 优缺点





优点: 1. MongoDB 是一个面向文档存储的数据库,操作起来比较简单和容易;

2.内置GridFS,支持大容量的存储;

- 3. 可以在MongoDB记录中设置任何属性的索引;
- 4. MongoDB支持各种编程语言:RUBY, PYTHON, JAVA, C++, PHP, C#等多种语言;
- 5.安装简单;
- 6.复制(复制集)和支持自动故障恢复;
- 7. MapReduce 支持复杂聚合。

缺点: 1.不支持事务;

- 2.占用空间过大;
- 3.不能进行表关联;
- 4.复杂聚合操作通过MapReduce创建,速度慢;
- 5. MongoDB 在你删除记录后不会在文件系统回收空间。除非你删掉数据库。

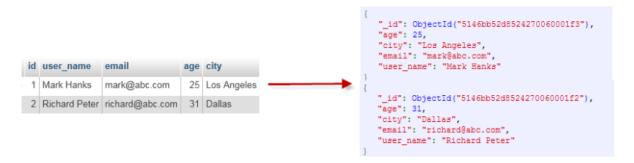
让天下没有难停的技术

5.3 基础概念解析

| SQL 术语/概念 | MongoDB 术语/概念 | 解释/说明 |
|-------------|---------------|---------------------------|
| database | database | 数据库 |
| table | collection | 数据库表/集合 |
| row | document | 数据记录行/文档 |
| column | field | 数据字段/域 |
| index | index | 索引 |
| table joins | 不支持 | 表连接,MongoDB 不支持 |
| primary key | primary key | 主键,MongoDB 自动将_id 字段设置为主键 |

通过下图实例,我们也可以更直观的了解 Mongo 中的一些概念:





5.4 安装

5.4.1 下载地址

https://www.mongodb.com/download-center#community

5.4.2 安装

1) 上传压缩包到虚拟机中,解压

[atguigu@hadoop102 software]\$ tar -zxvf mongodb-linux-x86_64-rhel70-5.0.2.tgz -C /opt/module/

2) 重命名

[atguigu@hadoop102 module]\$ mv mongodb-linux-x86 64- rhel70-5.0.2/ mongodb

3) 创建数据库目录

MongoDB 的数据存储在 data 目录的 db 目录下,但是这个目录在安装过程不会自动创建,所以需要手动创建 data 目录,并在 data 目录中创建 db 目录。

[atguigu@hadoop102 module]\$ sudo mkdir -p /data/db [atguigu@hadoop102 mongodb]\$ sudo chmod 777 -R /data/db/

5) 启动 MongoDB 服务

[atguigu@hadoop102 mongodb]\$ bin/mongod

6) 进入 shell 页面

[atguigu@hadoop102 mongodb]\$ bin/mongo

5.5 基础概念详解

5.5.1 数据库

一个 mongodb 中可以建立多个数据库。MongoDB 的默认数据库为"db",该数据库存储 更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



在 data 目录中。MongoDB 的单个实例可以容纳多个独立的数据库,每一个都有自己的集合和权限,不同的数据库也放置在不同的文件中。

1)显示所有数据库

> show dbs

admin 0.000GB

config 0.000GB

local 0.000GB

- ➤ admin:从权限的角度来看,这是"root"数据库。要是将一个用户添加到这个数据库,这个用户自动继承所有数据库的权限。一些特定的服务器端命令也只能从这个数据库运行,比如列出所有的数据库或者关闭服务器。
- ▶ local: 这个数据永远不会被复制,可以用来存储限于本地单台服务器的任意集合
- ➤ config: 当 Mongo 用于分片设置时, config 数据库在内部使用,用于保存分片的相关信息。
- 2)显示当前使用的数据库

> db

test

3) 切换数据库

> use local

switched to db local

> db

local

5.5.2 集合

集合就是 MongoDB 文档组,类似于 MySQL 中的 table。

集合存在于数据库中,集合没有固定的结构,这意味着你在对集合可以插入不同格式和 类型的数据,但通常情况下我们插入集合的数据都会有一定的关联性。

MongoDB 中使用 createCollection() 方法来创建集合。下面我们来看看如何创建集合: 语法格式:

db.createCollection(name, options)

参数说明:

name: 要创建的集合名称

options: 可选参数, 指定有关内存大小及索引的选项, 有以下参数:

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



| 字段 | 类型 | 描述 |
|-------------|----|--|
| capped | 布尔 | (可选)如果为 true,则创建固定集合。固定集合是指有着固定大小的集合,当达到最大值时,它会自动覆盖最早的文档。 当该值为 true 时,必须指定 size 参数。 |
| | | 当该值为 true 时,必须相定 Size 参数。 |
| autoIndexId | 布尔 | (可选)如为 true,自动在 _id 字段创建索引。默认为 false。 |
| size | 数值 | (可选)为固定集合指定一个最大值(以字节计)。 如果 capped 为 true,也需要指定该字段。 |
| max | 数值 | (可选)指定固定集合中包含文档的最大数量。 |

案例 1: 在 test 库中创建一个 atguigu 的集合

```
> use test
switched to db test
> db.createCollection("atguigu")
{ "ok" : 1 }
> show collections
Atguigu

//插入数据
> db.atguigu.insert({"name":"atguigu","url":"www.atguigu.com"})
WriteResult({ "nInserted" : 1 })

//查看数据
> db.atguigu.find()
{ "__id" : ObjectId("5d0314ceecb77ee2fb2d7566"), "name" : "atguigu", "url" : "www.atguigu.com" }
```

说明:

ObjectId 类似唯一主键,可以很快的去生成和排序,包含 12 bytes,由 24 个 16 进制数字组成的字符串(每个字节可以存储两个 16 进制数字),含义是:

- ▶ 前 4 个字节表示创建 unix 时间戳
- ▶ 接下来的 3 个字节是机器标识码
- ▶ 紧接的两个字节由进程 id 组成 PID
- ▶ 最后三个字节是随机数



案例 2: 创建一个固定集合 mycol

```
> db.createCollection("mycol", { capped : true, autoIndexId : true, size : 6142800, max : 1000})
> show tables;
atguigu
mycol
```

案例 3: 自动创建集合

在 MongoDB 中,你不需要创建集合。当你插入一些文档时,MongoDB 会自动创建集合。

```
> db.mycol2.insert({"name":"atguigu"})

WriteResult({ "nInserted" : 1 })

> show collections

atguigu

mycol

mycol2
```

案例 4: 删除集合

```
> db.mycol2.drop()

True
> show tables;
atguigu
mycol
```

5.5.3 文档(Document)

文档是一组键值(key-value)对组成。MongoDB 的文档不需要设置相同的字段,并且相同的字段不需要相同的数据类型,这与关系型数据库有很大的区别,也是 MongoDB 非常突出的特点。

一个简单的例子:

```
{"name":"atguigu"}
```

注意:

- 1、文档中的键/值对是有序的。
- 2、MongoDB区分类型和大小写。
- 3、MongoDB的文档不能有重复的键。
- 4、文档的键是字符串。除了少数例外情况,键可以使用任意 UTF-8 字符。



5.6 DataX 导入导出案例

5.6.1 读取 MongoDB 的数据导入到 HDFS

1) 编写配置文件

```
[atguigu@hadoop102 datax]$ vim job/mongdb2hdfs.json
    "job": {
          "content": [
              {
                   "reader": {
                        "name": "mongodbreader",
                        "parameter": {
                             "address": ["127.0.0.1:27017"],
                             "collectionName": "atguigu",
                             "column": [
                                       "name": "name",
                                       "type":"string"
                                  },
                                       "name":"url",
                                       "type":"string"
                             ],
                             "dbName": "test",
                   },
                   "writer": {
                        "name": "hdfswriter",
                        "parameter": {
                             "column": [
                                       "name":"name",
                                       "type":"string"
                                  },
                                       "name":"url",
```

更多 Java - 大数据 - 丽瑞 - python 人工智能贷料卜载, 可自度访问: 尚硅谷官网



```
"type":"string"
                               }
                         ],
                         "defaultFS": "hdfs://hadoop102:9000",
                         "fieldDelimiter": "\t",
                         "fileName": "mongo.txt",
                         "fileType": "text",
                         "path": "/",
                         "writeMode": "append"
               }
     ],
     "setting": {
          "speed": {
               "channel": "1"
     }
}
```

- 2) mongodbreader 参数解析
- ➤ address: MongoDB 的数据地址信息,因为 MonogDB 可能是个集群,则 ip 端口信息需要以 Json 数组的形式给出。【必填】
- ▶ userName: MongoDB 的用户名。【选填】
- ▶ userPassword: MongoDB 的密码。【选填】
- ▶ collectionName: MonogoDB 的集合名。【必填】
- ▶ column: MongoDB 的文档列名。【必填】
- ➤ name: Column 的名字。【必填】
- ▶ type: Column 的类型。【选填】
- > splitter: 因为 MongoDB 支持数组类型,但是 Datax 框架本身不支持数组类型,所以 mongoDB 读出来的数组类型要通过这个分隔符合并成字符串。【选填】
- 3) 执行

[atguigu@hadoop102 datax]\$ bin/datax.py job/mongdb2hdfs.json

4) 查看结果



| Permission | Owner | Group | Size | Last Modified | Replication | Block Size | Name |
|------------|---------|------------|-------|--------------------------------|-------------|------------|--|
| drwxr-xr-x | atguigu | supergroup | 0 B | Tue Apr 30 09:03:52 +0800 2019 | 0 | 0 B | hbase |
| -rw-rr | atguigu | supergroup | 24 B | Fri Jun 14 11:53:22 +0800 2019 | 3 | 128 MB | mongo.txt_1080895d_ec8a_4287_a665_5c0ceba5700f |
| -rw-rr | atguigu | supergroup | 110 B | Tue Apr 30 08:57:40 +0800 2019 | 3 | 128 MB | out.txt |
| -rw-rr | root | supergroup | 27 B | Wed Jun 12 14:09:00 +0800 2019 | 3 | 128 MB | student.csv |
| drwxrwx | atguigu | supergroup | 0 B | Fri Apr 26 14:45:09 +0800 2019 | 0 | 0 B | tmp |
| drwxr-xr-x | atguigu | supergroup | 0 B | Fri Apr 26 14:43:55 +0800 2019 | 0 | 0 B | user |

5.6.2 读取 MongoDB 的数据导入 MySQL

1) 在 MySQL 中创建表

```
mysql> create table atguigu(name varchar(20),url varchar(20));
```

2)编写 DataX 配置文件

```
[atguigu@hadoop102 datax]$ vim job/mongodb2mysql.json
    "job": {
         "content": [
              {
                   "reader": {
                        "name": "mongodbreader",
                        "parameter": {
                             "address": ["127.0.0.1:27017"],
                             "collectionName": "atguigu",
                             "column": [
                                       "name": "name",
                                       "type":"string"
                                  },
                                       "name":"url",
                                       "type":"string"
                             ],
                             "dbName": "test",
                        }
                   },
                   "writer": {
                        "name": "mysqlwriter",
                        "parameter": {
```



3) 执行

[atguigu@hadoop102 datax]\$ bin/datax.py job/mongodb2mysql.json

4) 查看结果

第6章 SQLServer

6.1 什么是 SQLServer

美国 Microsoft 公司推出的一种关系型数据库系统。SQL Server 是一个可扩展的、高性 更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



能的、为分布式客户机/服务器计算所设计的数据库管理系统,实现了与 WindowsNT 的有机结合,提供了基于事务的企业级信息管理系统方案。SQL Server 的基本语法和 MySQL 基本相同。

- (1) 高性能设计,可充分利用 WindowsNT 的优势。
- (2) 系统管理先进,支持 Windows 图形化管理工具,支持本地和远程的系统管理和配置。
 - (3) 强壮的事务处理功能,采用各种方法保证数据的完整性。
- (4) 支持对称多处理器结构、存储过程、ODBC,并具有自主的 SQL 语言。 SQLServer 以其内置的数据复制功能、强大的管理工具、与 Internet 的紧密集成和开放的系统结构为广大的用户、开发人员和系统集成商提供了一个出众的数据库平台。

6.2 安装

6.2.1 安装要求

系统要求:

- 1、centos 或 redhat7.0 以上系统
- 2、内存 2G 以上

说明:

linux 下安装 sqlserver 数据库有 2 种办法:

- ➤ 使用 rpm 安装包安装
 rpm 安装包地址: https://packages.microsoft.com/rhel/7/mssql-server-2017/
 安装时缺少什么依赖,就使用 yum 进行安装补齐
- ▶ 使用 yum 镜像安装

6.2.2 安装步骤

1)下载 Microsoft SQL Server 2017 Red Hat 存储库配置文件 sudo curl -o /etc/yum.repos.d/mssql-server.repo

https://packages.microsoft.com/config/rhel/7/mssql-server-2017.repo

2) 执行安装

yum install -y mssql-server



3) 完毕之后运行做相关配置

sudo /opt/mssql/bin/mssql-conf setup

6.2.3 安装配置

1) 执行配置命令

sudo /opt/mssql/bin/mssql-conf setup

2) 选择安装的版本

[atguigu@hadoop1 mssql]\$ sudo /opt/mssql/bin/mssql-conf setup 选择 SQL Server 的一个版本:
1) Evaluation (免费, 无生产许可, 180 天限制)
2) Developer (免费, 无生产许可)
3) Express (免费)
4) Web (付费版)
5) Standard (付费版)
6) Enterprise (付费版)

6) Enterprise (付费版)

7) Enterprise Core (付费版) 8) 我通过零售渠道购买了许可证并具有要输入的产品密钥。

可在以下位置找到有关版本的详细信息: https://go.microsoft.com/fwlink/?LinkId=852748&clcid=0x804

使用此软件的付费版本需要通过以下途径获取单独授权 Microsoft 批量许可计划。 选择付费版本即表示你具有适用的

要安装和运行此软件的就地许可证数量。

输入版本(1-8): 2 ■

3)接受许可条款

可以在以下位置找到此产品的许可条款: /usr/share/doc/mssql-server 或从以下位置下载: https://go.microsoft.com/fwlink/?LinkId=855862&clcid=0x804

可以从以下位置查看隐私声明:

https://go.microsoft.com/fwlink/?LinkId=853010&clcid=0x804

接受此许可条款吗? [Yes/No]:yes

3)选择语言

选择 SQL Server 的语言: (1) English (2) Deutsch (3) Español (4) Français (5) Italiano (6) 日本語 (7) 한국 어 (8) Português (9) Русский (10) 中文 - 简体 (11) 中文 (繁体) 输入选项 1-11:10

4) 配置系统管理员密码

指定的密码不符合 SQL Server 密码策略要求,因为它不够复杂。密码必须至少包含 8 个字符,并包含以下四种字符集中的任意三种:大<u>写字母、小写</u> 字母、数字相符号。 输入 SQL Server 系统管理员密码: 确认 SQL Server 系统管理员密码: 正在配置 SQL Server...



5) 完成

6.2.4 安装命令行工具

1)下载存储库配置文件

sudo curl -o /etc/yum.repos.d/msprod.repo https://packages.microsoft.com/config/rhel/7/prod.repo

2) 执行安装

sudo yum remove mssql-tools unixODBC-utf16-devel sudo yum install mssql-tools unixODBC-devel

3) 配置环境变量

sudo vim /etc/profile.d/my env.sh

#添加环境变量

export PATH="\$PATH:/opt/mssql-tools/bin

source /etc/profile.d/my_env.sh

4) 进入命令行

sqlcmd -S localhost -U SA -P 密码 # 用命令行连接

6.3 简单使用

6.3.1 启停命令

#启动

systemctl start mssql-server

#重启

systemctl restart mssql-server

#停止

systemctl stop mssql-server

#查看状态

systemetl status mssql-server

#具体配置路径

/opt/mssql/bin/mssql-conf



6.3.2 创建数据库

1) 建库

```
> create database datax
> go

(2) 看当前数据库列表
> select * from SysDatabases
> go

(3) 看当前数据表
> use 库名
> select * from sysobjects where xtype='u'
> go

(4) 看表的内容
> select * from 表名;
> go
```

6.4 DataX 导入导出案例

创建表并插入数据

```
create table student(id int,name varchar(25))
go
insert into student values(1,'zhangsan')
go
```

6.4.1 读取 SQLServer 的数据导入到 HDFS

1) 编写配置文件

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
"id",
                                   "name"
                             ],
                              "connection": [
                                        "jdbcUrl": [
"jdbc:sqlserver://hadoop2:1433;DatabaseName=datax"
                                       ],
                                        "table": [
                                             "student"
                                       ]
                             ],
                              "username": "root",
                              "password": "000000"
                         }
                    },
                    "writer": {
                         "name": "hdfswriter",
                         "parameter": {
                              "column": [
                                        "name": "id",
                                       "type": "int"
                                   },
                                        "name": "name",
                                       "type": "string"
                                   }
                              "defaultFS": "hdfs://hadoop102:9000",
                              "fieldDelimiter": "\t",
                              "fileName": "sqlserver.txt",
                              "fileType": "text",
                              "path": "/",
                              "writeMode": "append"
                         }
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
}
}

],

"setting": {
    "speed": {
        "channel": "1"
     }
}
```

6.4.2 读取 SQLServer 的数据导入 MySQL

```
[atguigu@hadoop102 datax]$ vim job/sqlserver2mysql.json
    "job": {
          "content": [
                   "reader": {
                        "name": "sqlserverreader",
                        "parameter": {
                             "column": [
                                  "id",
                                  "name"
                             ],
                             "connection": [
                                       "jdbcUrl": [
"jdbc:sqlserver://hadoop2:1433;DatabaseName=datax"
                                       ],
                                       "table": [
                                            "student"
                             ],
                             "username": "root",
                             "password": "000000"
                        }
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
},
          "writer": {
               "name": "mysqlwriter",
               "parameter": {
                    "column": ["*"],
                    "connection": [
                              "jdbcUrl": "jdbc:mysql://hadoop102:3306/datax",
                              "table": ["student"]
                   ],
                    "password": "000000",
                    "username": "root",
                    "writeMode": "insert"
     }
],
"setting": {
     "speed": {
          "channel": "1"
```

第7章 DB2

7.1 什么是 db2

DB2 是 IBM 公司于 1983 年研制的一种关系型数据库系统(Relational Database Management System),主要应用于大型应用系统,具有较好的可伸缩性 。DB2 是 IBM 推出的第二个关系型数据库,所以称为 db2。DB2 提供了高层次的数据利用性、完整性、安全性、并行性、可恢复性,以及小规模到大规模应用程序的执行能力,具有与平台无关的基本功能和 SQL 命令运行环境。可以同时在不同操作系统使用,包括 Linux、UNIX 和 Windows。



7.2 db2 数据库对象关系

- 1、instance, 同一台机器上可以安装多个 DB2 instance。
- 2、database, 同一个 instance 下面可以创建有多个 database。
- 3、schema, 同一个 database 下面可以配置多个 schema。
- 4、table,同一个schema下可以创建多个table。

7.3 安装前的准备

7.3.1 安装依赖

yum install -y bc binutils compat-libcap1 compat-libstdc++33 elfutils-libelf elfutils-libelf-devel fontconfig-devel glibc glibc-devel ksh libaio libaio-devel libX11 libXau libXi libXtst libXrender libXrender-devel libgcc libstdc++ libstdc++-devel libxcb make smartmontools sysstat kmod* gcc-c++ compat-libstdc++-33 libstdc++.so.6 kernel-devel pam-devel.i686 pam.i686 pam32*

7.3.2 修改配置文件 sysctl.conf

[root@hadoop102 module]# vim /etc/sysctl.conf

删除里面的内容,添加如下内容:

net.ipv4.ip local port range = 9000 65500

fs.file-max = 6815744

kernel.shmall = 10523004

kernel.shmmax = 6465333657

kernel.shmmni = 4096

 $kernel.sem = 250 \ 32000 \ 100 \ 128$

net.core.rmem default=262144

net.core.wmem default=262144

net.core.rmem max=4194304

net.core.wmem_max=1048576

fs.aio-max-nr = 1048576

7.3.3 修改配置文件 limits.conf

[root@hadoop102 module]# vim /etc/security/limits.conf

在文件末尾添加:

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



- * soft nproc 65536
- * hard nproc 65536
- * soft nofile 65536
- * hard nofile 65536

重启机器生效。

7.3.4 上传安装包并解压

[root@hadoop102 software]# tar -zxvf v11.5.4_linuxx64_server_dec.tar.gz -C /opt/module/ [root@hadoop102 module]# chmod 777 server_dec

7.4 安装

在 root 用户下操作

7.4.1 执行预检查命令

./db2prereqcheck -l -s //检查环境

7.4.2 执行安装

./db2_install

1)接受许可条款

可能会出现两次询问是否接受条款,都选"是"即可。

2) 确认安装路径,默认

3) 选择安装 SERVER



指定下列其中一个关键字以安装 Db2 产品。

SERVER CONSV CLIENT RTCL

输入 "help" 以重新显示产品名称。

输入 "quit" 以退出。

SERVER

4) 不安装 pureScale

等待安装完成即可

5) 查看许可

/opt/ibm/db2/V11.5/adm/db2licm -l

7.4.3 添加组和用户

groupadd -g 2000 db2iadm1
groupadd -g 2001 db2fadm1
useradd -m -g db2iadm1 -d /home/db2inst1 db2inst1
useradd -m -g db2fadm1 -d /home/db2fenc1 db2fenc1
passwd db2inst1
passwd db2fenc1

▶ db2inst1: 实例所有者

▶ db2fenc1: 受防护用户

7.4.4 创建实例

cd /opt/ibm/db2/V11.5/instance ./db2icrt -p 50000 -u db2fenc1 db2inst1

7.4.5 创建样本数据库、开启服务

su - db2inst1 db2sampl db2start



7.4.6 连接

```
db2
conncet to sample #连接到某个数据库
select * from staff
```

7.4.7 创建表、插入数据

```
CREATE TABLE STUDENT(ID int ,NAME varchar(20));
INSERT INTO STUDENT VALUES(11, 'lisi');
commit;
```

7.5 DataX 导入导出案例

7.5.1 注册 db2 驱动

datax 暂时没有独立插件支持 db2,需要使用通用的使用 rdbmsreader 或 rdbmswriter。

1) 注册 reader 的 db2 驱动

```
[atguigu@hadoop102 datax]$ vim /opt/module/datax/plugin/reader/rdbmsreader/plugin.json #在 drivers 里添加 db2 的驱动类
"drivers":["dm.jdbc.driver.DmDriver", "com.sybase.jdbc3.jdbc.SybDriver",
"com.edb.Driver","com.ibm.db2.jcc.DB2Driver"]
```

2) 注册 writer 的 db2 驱动

```
[atguigu@hadoop102 datax]$ vim /opt/module/datax/plugin/writer/rdbmswriter/plugin.json #在 drivers 里添加 db2 的驱动类 "drivers":["dm.jdbc.driver.DmDriver", "com.sybase.jdbc3.jdbc.SybDriver", "com.edb.Driver","com.ibm.db2.jcc.DB2Driver"]
```

7.5.2 读取 DB2 的数据导入到 HDFS

1)编写配置文件

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



```
"parameter": {
         "column": [
              "ID",
              "NAME"
         ],
         "connection": [
              {
                   "jdbcUrl": [
                        "jdbc:db2://hadoop2:50000/sample"
                   ],
                   "table": [
                        "STUDENT"
                   ]
         ],
         "username": "db2inst1",
         "password": "atguigu"
},
"writer": {
     "name": "hdfswriter",
     "parameter": {
          "column": [
                   "name": "id",
                   "type": "int"
              },
                   "name": "name",
                   "type": "string"
              }
         ],
         "defaultFS": "hdfs://hadoop102:9000",
         "fieldDelimiter": "\t",
         "fileName": "db2.txt",
         "fileType": "text",
         "path": "/",
         "writeMode": "append"
```



```
}
}

],

"setting": {
    "speed": {
        "channel": "1"
    }
}
```

7.5.3 读取 DB2 的数据导入 MySQL

```
[atguigu@hadoop102 datax]$ vim job/db2-2-mysql.json
    "job": {
         "content": [
                   "reader": {
                        "name": "rdbmsreader",
                        "parameter": {
                            "column": [
                                 "ID",
                                 "NAME"
                            ],
                            "connection": [
                                      "jdbcUrl": [
                                           "jdbc:db2://hadoop2:50000/sample"
                                      ],
                                      "table": [
                                           "STUDENT"
                                      ]
                                 }
                            ],
                            "username": "db2inst1",
                            "password": "atguigu"
                        }
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网

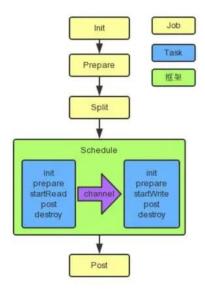


```
},
          "writer": {
               "name": "mysqlwriter",
               "parameter": {
                    "column": ["*"],
                    "connection": [
                              "jdbcUrl": "jdbc:mysql://hadoop102:3306/datax",
                             "table": ["student"]
                   ],
                    "password": "000000",
                    "username": "root",
                    "writeMode": "insert"
     }
],
"setting": {
     "speed": {
         "channel": "1"
```



第8章 执行流程源码分析

8.1 总体流程



- ▶ 黄色: Job 部分的执行阶段,
- ▶ 蓝色: Task 部分的执行阶段,
- ▶ 绿色:框架执行阶段。

8.2 程序入口

```
datax.py
.....

ENGINE_COMMAND = "java -server ${jvm} %s -classpath %s ${params}

com.alibaba.datax.core.Engine -mode ${mode} -jobid ${jobid} -job ${job}" % (

DEFAULT_PROPERTY_CONF, CLASS_PATH)
.....
```

Engine.java

```
public void start(Configuration allConf) {

.....

//JobContainer 会在 schedule 后再行进行设置和调整值
int channelNumber =0;
AbstractContainer container;
```

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网



```
long instanceId;
        int taskGroupId = -1;
        if (isJob) {
            allConf.set(CoreConstant.DATAX CORE CONTAINER JOB MODE,
RUNTIME MODE);
            container = new JobContainer(allConf);
            instanceId = allConf.getLong(
                     CoreConstant.DATAX CORE CONTAINER JOB ID, 0);
        } else {
            container = new TaskGroupContainer(allConf);
            instanceId = allConf.getLong(
                     CoreConstant.DATAX_CORE_CONTAINER_JOB_ID);
            taskGroupId = allConf.getInt(
                     CoreConstant.DATAX CORE CONTAINER TASKGROUP ID);
            channelNumber = allConf.getInt(
CoreConstant.DATAX_CORE_CONTAINER_TASKGROUP_CHANNEL);
        }
        container.start();
    }
```

JobContainer.java

```
**

* jobContainer 主要负责的工作全部在 start()里面,包括 init、prepare、split、scheduler、

* post 以及 destroy 和 statistics

*/

@Override
public void start() {

LOG.info("DataX jobContainer starts job.");

boolean hasException = false;
boolean isDryRun = false;
try {

this.startTimeStamp = System.currentTimeMillis();
isDryRun =

configuration.getBool(CoreConstant.DATAX_JOB_SETTING_DRYRUN, false);

更多 Java - 大数据 - 前端 - python 人工智能資料卜载,可自度访问: 尚佳谷官网
```



```
if(isDryRun) {
              LOG.info("jobContainer starts to do preCheck ...");
              this.preCheck();
         } else {
              userConf = configuration.clone();
              LOG.debug("jobContainer starts to do preHandle ...");
              //Job 前置操作
              this.preHandle();
              LOG.debug("jobContainer starts to do init ...");
              //初始化 reader 和 writer
              this.init();
              LOG.info("jobContainer starts to do prepare ...");
              //全局准备工作,比如 odpswriter 清空目标表
              this.prepare();
              LOG.info("jobContainer starts to do split ...");
              //拆分 Task
              this.totalStage = this.split();
              LOG.info("jobContainer starts to do schedule ...");
              this.schedule();
              LOG.debug("jobContainer starts to do post ...");
              this.post();
              LOG.debug("jobContainer starts to do postHandle ...");
              this.postHandle();
              LOG.info("DataX jobId [{}] completed successfully.", this.jobId);
              this.invokeHooks();
    } .....
}
```

8.3 Task 切分逻辑

```
JobContainer.java
```

```
private int split() {
    this.adjustChannelNumber();
```



```
if (this.needChannelNumber <= 0) {
              this.needChannelNumber = 1;
         }
         List<Configuration> readerTaskConfigs = this
                  .doReaderSplit(this.needChannelNumber);
         int taskNumber = readerTaskConfigs.size();
         List<Configuration> writerTaskConfigs = this
                  .doWriterSplit(taskNumber);
         List<Configuration> transformerList =
this.configuration.getListConfiguration(CoreConstant.DATAX JOB CONTENT TRANSF
ORMER);
         LOG.debug("transformer configuration: "+ JSON.toJSONString(transformerList));
         /**
          * 输入是 reader 和 writer 的 parameter list,输出是 content 下面元素的 list
          */
         List<Configuration> contentConfig = mergeReaderAndWriterTaskConfigs(
                  readerTaskConfigs, writerTaskConfigs, transformerList);
         LOG.debug("contentConfig configuration: "+
JSON.toJSONString(contentConfig));
         this.configuration.set(CoreConstant.DATAX JOB CONTENT, contentConfig);
         return contentConfig.size();
```

8.3.1 并发数的确定



```
if (isByteLimit) {
            long globalLimitedByteSpeed = this.configuration.getInt(
                     CoreConstant.DATAX JOB SETTING SPEED BYTE, 10 * 1024
* 1024);
            // 在 byte 流控情况下,单个 Channel 流量最大值必须设置,否则报错!
            Long channelLimitedByteSpeed = this.configuration
                     .getLong(CoreConstant.DATAX CORE TRANSPORT CHANNE
L SPEED BYTE);
            if (channelLimitedByteSpeed == null || channelLimitedByteSpeed <= 0) {
                throw DataXException.asDataXException(
                         FrameworkErrorCode.CONFIG ERROR,
                         "在有总 bps 限速条件下,单个 channel 的 bps 值不能为
空,也不能为非正数");
            needChannelNumberByByte =
                     (int) (globalLimitedByteSpeed / channelLimitedByteSpeed);
            needChannelNumberByByte =
                     needChannelNumberByByte > 0 ? needChannelNumberByByte : 1;
            LOG.info("Job set Max-Byte-Speed to " + globalLimitedByteSpeed + "
bytes.");
        }
        boolean isRecordLimit = (this.configuration.getInt(
                CoreConstant.DATAX JOB SETTING SPEED RECORD, 0)) > 0;
        if (isRecordLimit) {
            long globalLimitedRecordSpeed = this.configuration.getInt(
                     CoreConstant.DATAX JOB SETTING SPEED RECORD,
100000);
            Long channelLimitedRecordSpeed = this.configuration.getLong(
CoreConstant.DATAX CORE TRANSPORT CHANNEL SPEED RECORD);
            if (channelLimitedRecordSpeed == null || channelLimitedRecordSpeed <= 0)
                throw
DataXException.asDataXException(FrameworkErrorCode.CONFIG ERROR,
```



```
"在有总 tps 限速条件下,单个 channel 的 tps 值不能为空,
也不能为非正数");
            needChannelNumberByRecord =
                     (int) (globalLimitedRecordSpeed / channelLimitedRecordSpeed);
            needChannelNumberByRecord =
                     needChannelNumberByRecord > 0?
needChannelNumberByRecord: 1;
            LOG.info("Job set Max-Record-Speed to " + globalLimitedRecordSpeed + "
records.");
        // 取较小值
        this.needChannelNumber = needChannelNumberByByte <
needChannelNumberByRecord?
                needChannelNumberByByte: needChannelNumberByRecord;
        // 如果从 byte 或 record 上设置了 needChannelNumber 则退出
        if (this.needChannelNumber < Integer.MAX VALUE) {
            return;
        }
        boolean isChannelLimit = (this.configuration.getInt(
                CoreConstant.DATAX JOB SETTING SPEED CHANNEL, 0) > 0);
        if (isChannelLimit) {
            this.needChannelNumber = this.configuration.getInt(
                     CoreConstant.DATAX JOB SETTING SPEED CHANNEL);
            LOG.info("Job set Channel-Number to " + this.needChannelNumber
                    + " channels.");
            return;
        }
        throw DataXException.asDataXException(
                FrameworkErrorCode.CONFIG ERROR,
                "Job 运行速度必须设置");
```



8.4 调度

JobContainer.java

```
private void schedule() {
         * 这里的全局 speed 和每个 channel 的速度设置为 B/s
         */
        int channelsPerTaskGroup = this.configuration.getInt(
CoreConstant.DATAX CORE CONTAINER TASKGROUP CHANNEL, 5);
        int taskNumber = this.configuration.getList(
                CoreConstant.DATAX JOB CONTENT).size();
        //确定的 channel 数和切分的 task 数取最小值,避免浪费
        this.needChannelNumber = Math.min(this.needChannelNumber, taskNumber);
        PerfTrace.getInstance().setChannelNumber(needChannelNumber);
        /**
         * 通过获取配置信息得到每个 taskGroup 需要运行哪些 tasks 任务
         */
        List<Configuration> taskGroupConfigs =
JobAssignUtil.assignFairly(this.configuration,
                this.needChannelNumber, channelsPerTaskGroup);
        LOG.info("Scheduler starts [{}] taskGroups.", taskGroupConfigs.size());
        ExecuteMode executeMode = null;
        AbstractScheduler scheduler;
        try {
            //可以看到 3.0 进行了阉割,只有 STANDALONE 模式
            executeMode = ExecuteMode.STANDALONE;
            scheduler = initStandaloneScheduler(this.configuration);
            //设置 executeMode
            for (Configuration taskGroupConfig : taskGroupConfigs) {
```



```
taskGroupConfig.set(CoreConstant.DATAX CORE CONTAINER JOB MODE,
executeMode.getValue());
             if (executeMode == ExecuteMode.LOCAL || executeMode ==
ExecuteMode.DISTRIBUTE) {
                 if (this.jobId \le 0) {
                     throw
DataXException.asDataXException(FrameworkErrorCode.RUNTIME ERROR,
                              "在[local | distribute ]模式下必须设置 jobId, 并且其
值 > 0.");
            LOG.info("Running by {} Mode.", executeMode);
             this.startTransferTimeStamp = System.currentTimeMillis();
             scheduler.schedule(taskGroupConfigs);
             this.endTransferTimeStamp = System.currentTimeMillis();
        } catch (Exception e) {
             LOG.error("运行 scheduler 模式[{}]出错.", executeMode);
             this.endTransferTimeStamp = System.currentTimeMillis();
             throw DataXException.asDataXException(
                     FrameworkErrorCode.RUNTIME ERROR, e);
        }
          * 检查任务执行情况
        this.checkLimit();
```

8.4.1 确定组数和分组

assignFairly 方法:



- 1) 确定 taskGroupNumber,
- 2) 做分组分配,
- 3) 做分组优化

```
public static List<Configuration> assignFairly(Configuration configuration, int
channelNumber, int channelsPerTaskGroup) {
        Validate.isTrue(configuration!= null, "框架获得的 Job 不能为 null.");
        List<Configuration> contentConfig =
configuration.getListConfiguration(CoreConstant.DATAX JOB CONTENT);
        Validate.isTrue(contentConfig.size() > 0, "框架获得的切分后的 Job 无内容.");
        Validate.isTrue(channelNumber > 0 && channelsPerTaskGroup > 0,
                "每个 channel 的平均 task 数[averTaskPerChannel], channel 数目
[channelNumber],每个taskGroup的平均channel数[channelsPerTaskGroup]都应该为正
数");
        //TODO 确定 taskgroup 的数量
        int taskGroupNumber = (int) Math.ceil(1.0 * channelNumber /
channelsPerTaskGroup);
        Configuration aTaskConfig = contentConfig.get(0);
        String readerResourceMark =
aTaskConfig.getString(CoreConstant.JOB READER PARAMETER + "." +
                CommonConstant.LOAD BALANCE RESOURCE MARK);
        String writerResourceMark =
aTaskConfig.getString(CoreConstant.JOB WRITER PARAMETER + "." +
                CommonConstant.LOAD BALANCE RESOURCE MARK);
        boolean hasLoadBalanceResourceMark =
StringUtils.isNotBlank(readerResourceMark) ||
                StringUtils.isNotBlank(writerResourceMark);
        if (!hasLoadBalanceResourceMark) {
            // fake 一个固定的 key 作为资源标识(在 reader 或者 writer 上均可,
此处选择在 reader 上进行 fake)
```



8.4.2 调度实现

AbstractScheduler.java



```
/**
           * 给 taskGroupContainer 的 Communication 注册
           */
          this.containerCommunicator.registerCommunication(configurations);
         int totalTasks = calculateTaskCount(configurations);
          startAllTaskGroup(configurations);
          Communication lastJobContainerCommunication = new Communication();
         long lastReportTimeStamp = System.currentTimeMillis();
          try {
              while (true) {
                   /**
                     * step 1: collect job stat
                     * step 2: getReport info, then report it
                     * step 3: errorLimit do check
                     * step 4: dealSucceedStat();
                     * step 5: dealKillingStat();
                     * step 6: dealFailedStat();
                     * step 7: refresh last job stat, and then sleep for next while
                     * above steps, some ones should report info to DS
                     */
ProcessInnerScheduler.java
```

```
public void startAllTaskGroup(List<Configuration> configurations) {
         this.taskGroupContainerExecutorService = Executors
                  .newFixedThreadPool(configurations.size());
         for (Configuration taskGroupConfiguration : configurations) {
              TaskGroupContainerRunner taskGroupContainerRunner =
newTaskGroupContainerRunner(taskGroupConfiguration);
```



```
this.taskGroupContainerExecutorService.execute(taskGroupContainerRunner);
         this.taskGroupContainerExecutorService.shutdown();
    }
```

8.5 数据传输

```
接 8.3.2 丢到线程池执行
TaskGroupContainer.start()
    -> taskExecutor.doStart()
可以看到调用插件的 start 方法
public void doStart() {
    this.writerThread.start();
    // reader 没有起来, writer 不可能结束
    if (!this.writerThread.isAlive() || this.taskCommunication.getState() == State.FAILED) {
         throw DataXException.asDataXException(
                 FrameworkErrorCode.RUNTIME ERROR,
                 this.taskCommunication.getThrowable());
    }
    this.readerThread.start();
```

可以看看 generateRunner()

ReaderRunner.java

```
public void run() {
     .....
     try {
          channelWaitWrite.start();
          initPerfRecord.start();
          taskReader.init();
          initPerfRecord.end();
```



```
. . . . . .
              preparePerfRecord.start();
              taskReader.prepare();
              preparePerfRecord.end();
              dataPerfRecord.start();
              taskReader.startRead(recordSender);
              recordSender.terminate();
              postPerfRecord.start();
              taskReader.post();
              postPerfRecord.end();
              // automatic flush
              // super.markSuccess(); 这里不能标记为成功,成功的标志由
 writerRunner 来标志(否则可能导致 reader 先结束,而 writer 还没有结束的严重
 bug)
          } catch (Throwable e) {
              LOG.error("Reader runner Received Exceptions:", e);
              super.markFail(e);
          } finally {
              LOG.debug("task reader starts to do destroy ...");
              PerfRecord desPerfRecord = new PerfRecord(getTaskGroupId(), getTaskId(),
 PerfRecord.PHASE.READ TASK DESTROY);
              desPerfRecord.start();
              super.destroy();
              desPerfRecord.end();
 channelWaitWrite.end(super.getRunnerCommunication().getLongCounter(CommunicationTo
 ol.WAIT_WRITER_TIME));
              long transformerUsedTime =
 super.getRunnerCommunication().getLongCounter(CommunicationTool.TRANSFORMER
 USED TIME);
              if (transformerUsedTime > 0) {
更多 Java - 大数据 - 前端 - python 人工智能资料卜载,可自度访问: 尚硅谷官网
```



```
PerfRecord transformerRecord = new PerfRecord(getTaskGroupId(),
getTaskId(), PerfRecord.PHASE.TRANSFORMER TIME);
                 transformerRecord.start();
                 transformerRecord.end(transformerUsedTime);
        }
```

8.5.1 限速的实现

比如看 MysqlReader 的 startReader 方法

- -> CommonRdbmsReaderTask.startRead()
 - -> transportOneRecord()
 - -» sendToWriter()
 - -> BufferedRecordExchanger. flush()
 - -> Channel.pushAll()
 - -> Channel. statPush()

```
private void statPush(long recordSize, long byteSize) {
currentCommunication.increaseCounter(CommunicationTool.READ SUCCEED RECORD
S,
            recordSize);
currentCommunication.increaseCounter(CommunicationTool.READ SUCCEED BYTES,
            byteSize);
    //在读的时候进行统计 waitCounter 即可, 因为写 (pull) 的时候可能正在阻塞,
但读的时候已经能读到这个阻塞的 counter 数
    currentCommunication.setLongCounter(CommunicationTool.WAIT READER TIME,
waitReaderTime);
    currentCommunication.setLongCounter(CommunicationTool.WAIT WRITER TIME,
waitWriterTime);
    boolean isChannelByteSpeedLimit = (this.byteSpeed > 0);
    boolean isChannelRecordSpeedLimit = (this.recordSpeed > 0);
    if (!isChannelByteSpeedLimit && !isChannelRecordSpeedLimit) {
        return:
```



```
long lastTimestamp = lastCommunication.getTimestamp();
    long nowTimestamp = System.currentTimeMillis();
    long interval = nowTimestamp - lastTimestamp;
    if (interval - this.flowControlInterval >= 0) {
         long byteLimitSleepTime = 0;
         long recordLimitSleepTime = 0;
         if (isChannelByteSpeedLimit) {
             long currentByteSpeed =
(CommunicationTool.getTotalReadBytes(currentCommunication) -
                       CommunicationTool.getTotalReadBytes(lastCommunication)) *
1000 / interval:
             if (currentByteSpeed > this.byteSpeed) {
                  // 计算根据 byteLimit 得到的休眠时间
                  byteLimitSleepTime = currentByteSpeed * interval / this.byteSpeed
                           - interval:
             }
         }
         if (isChannelRecordSpeedLimit) {
             long currentRecordSpeed =
(CommunicationTool.getTotalReadRecords(currentCommunication) -
                       CommunicationTool.getTotalReadRecords(lastCommunication)) *
1000 / interval;
             if (currentRecordSpeed > this.recordSpeed) {
                  // 计算根据 recordLimit 得到的休眠时间
                  recordLimitSleepTime = currentRecordSpeed * interval /
this.recordSpeed
                           - interval:
             }
         }
        // 休眠时间取较大值
         long sleepTime = byteLimitSleepTime < recordLimitSleepTime ?</pre>
                  recordLimitSleepTime: byteLimitSleepTime;
         if (sleepTime > 0) {
             try {
```



```
Thread.sleep(sleepTime);
} catch (InterruptedException e) {
    Thread.currentThread().interrupt();
}

.....
}
```

第9章 DataX 使用优化

9.1 关键参数

- > job.setting.speed.channel: channel 并发数
- ▶ job.setting.speed.record: 2 全局配置 channel 的 record 限速
- > job.setting.speed.byte: 全局配置 channel 的 byte 限速
- > core.transport.channel.speed.record: 单个 channel 的 record 限速
- ➤ core.transport.channel.speed.byte: 单个 channel 的 byte 限速

9.2 优化 1: 提升每个 channel 的速度

在 DataX 内部对每个 Channel 会有严格的速度控制,分两种,一种是控制每秒同步的记录数,另外一种是每秒同步的字节数,默认的速度限制是 1MB/s,可以根据具体硬件情况设置这个 byte 速度或者 record 速度,一般设置 byte 速度,比如:我们可以把单个 Channel 的速度上限配置为 5MB

9.3 优化 2: 提升 DataX Job 内 Channel 并发数

并发数 = taskGroup 的数量 * 每个 TaskGroup 并发执行的 Task 数 (默认为 5)。 提升 job 内 Channel 并发有三种配置方式:

9.3.1 配置全局 Byte 限速以及单 Channel Byte 限速

Channel 个数 = 全局 Byte 限速 / 单 Channel Byte 限速 更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



core.transport.channel.speed.byte=1048576, job.setting.speed.byte=5242880, 所以 Channel 个数 = 全局 Byte 限速 / 单 Channel Byte 限速=5242880/1048576=5 个

9.3.2 配置全局 Record 限速以及单 Channel Record 限速

Channel 个数 = 全局 Record 限速 / 单 Channel Record 限速

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



```
"record": 500
}
, ...
}
}
```

core.transport.channel.speed.record=100 , job.setting.speed.record=500, 所 以 配 置 全 局 Record 限速以及单 Channel Record 限速,Channel 个数 = 全局 Record 限速 / 单 Channel Record 限速=500/100=5

9.3.3 直接配置 Channel 个数

只有在上面两种未设置才生效,上面两个同时设置是取值小的作为最终的 channel 数。

直接配置 job.setting.speed.channel=5, 所以 job 内 Channel 并发=5 个

9.4 优化 3: 提高 JVM 堆内存

当提升 DataX Job 内 Channel 并发数时,内存的占用会显著增加,因为 DataX 作为数据交换通道,在内存中会缓存较多的数据。例如 Channel 中会有一个 Buffer,作为临时的数据交换的缓冲区,而在部分 Reader 和 Writer 的中,也会存在一些 Buffer,为了防止 OOM 等错误,调大 JVM 的堆内存。

建议将内存设置为 4G 或者 8G, 这个也可以根据实际情况来调整。

调整 JVM xms xmx 参数的两种方式:一种是直接更改 datax.py 脚本;另一种是在启动的时候,加上对应的参数,如下:

python datax/bin/datax.py --jvm="-Xms8G -Xmx8G" XXX.json

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问:尚硅谷官网